



UNIVERSIDADE FEDERAL DE SÃO PAULO
Departamento de Ciência e Tecnologia
Bacharelado em Ciência da Computação

Davi Seiji Kawai Santos

Segmentação de Bola de Basquete com técnicas de Processamento
de Imagens.

Trabalho da UC - Processamento de Imagens

Prof. Dra. Regina Célia Coelho

São José dos Campos, Dezembro de 2025

Sumário

1	Introdução	1
2	Objetivo	1
3	Metodologia	2
3.1	Base de Dados	2
3.2	Pré-processamento	2
3.3	Segmentação	3
3.3.1	Segmentação em HSV	3
3.3.2	Segmentação em LAB	3
3.3.3	Segmentação em Tons de Cinza	3
3.4	Pós-processamento	4
3.5	Avaliação da Segmentação	4
3.6	Seleção do Melhor Método por Imagem	4
3.7	Ranking Final dos Métodos	5
4	Resultados e Discussões	5
4.1	Desempenho Geral dos Métodos	6
4.2	Análise dos 10 melhores modelos no geral	7
4.3	Análise dos 10 piores modelos no geral	8
4.4	Síntese dos Resultados	9
5	Conclusão	9
	Referências Bibliográficas	10

1 Introdução

O processamento de imagens desempenha um papel fundamental sendo muito útil em diversas áreas. A segmentação, que é o foco desse trabalho, consiste no processo de separar objetos de interesse, permitindo a análise de algum elemento específico de uma imagem. Apesar de ser uma tarefa clássica, a segmentação ainda apresenta desafios quando o objeto possui diferentes formatos e cores, quando a iluminação da imagem não é favorável ou quando tem pouca diferença do objeto com o fundo.

Neste projeto, foi proposto o estudo e a análise de diferentes técnicas de pré-processamento e segmentação aplicadas a um conjunto de imagens contendo uma bola de basquete. A bola é um objeto com coloração e formato característica, porém em algumas imagens, suas características, como por exemplo a iluminação e posição da bola, podem dificultar a segmentação da mesma.

A segmentação de uma bola de basquete pode ser útil em diversas aplicações práticas, como sistemas de análise esportiva, detecção automática de quadras, monitoramento de movimentos em partidas e até auxílio em treinamentos, onde é necessário acompanhar a trajetória do objeto. Além disso, a extração precisa da bola pode servir como etapa inicial para sistemas mais avançados, como rastreamento ou análise tática, reforçando a relevância do estudo de métodos de segmentação robustos e eficientes.

A partir dos conhecimentos adquiridos na disciplina, foram aplicadas técnicas baseadas em diferentes espaços de cor (HSV, Lab e escala de cinza), filtros de realce e suavização, segmentação por limiarização e Hough, além de operações morfológicas para pós-processamento. O projeto busca demonstrar o impacto de cada etapa sobre a qualidade final da segmentação.

2 Objetivo

O objetivo central deste trabalho é desenvolver e testar um sistema capaz de segmentar a bola de basquete em imagens, avaliando diferentes métodos de pré-processamento, segmentação e pós-processamento para identificar quais combinações apresentam o melhor desempenho. Para isso, os objetivos específicos são:

- Desenvolver funções de pré-processamento de imagens;
- Implementar diferentes técnicas de segmentação;
- Aplicar operações de pós-processamento para aprimorar as máscaras obtidas;
- Testar diversas combinações de métodos e validá-las utilizando a métrica Dice.

3 Metodologia

A metodologia adotada neste trabalho consiste na avaliação de diferentes estratégias de pré-processamento e segmentação para detecção de bolas de basquete em imagens. O pipeline completo é composto por três etapas principais: pré-processamento, segmentação e pós-processamento. A qualidade das máscaras geradas no final é avaliada quantitativamente por meio do coeficiente de Dice, comparando-as com as máscaras reais.

3.1 Base de Dados

As imagens foram retiradas de uma plataforma chamada Kaggle, que oferece diversos recursos e bases de dados para o aprendizado. O dataset selecionado está disponível no link: <https://universe.roboflow.com/suya-1wirw/basketball-bgxzc>, onde existem 150 imagens com suas máscaras reais, indicando onde está a bola de basquete.

Para facilitar o entendimento de como está funcionando os modelos testados, eles foram submetidos a 30 imagens, retiradas do dataset descrito acima. As imagens utilizadas foram organizadas na pasta `data/img`, enquanto as máscaras reais estavam disponíveis em `data/real_masks`. Para cada imagem no formato `.jpg`, existe uma máscara correspondente em `.png`.

3.2 Pré-processamento

O objetivo do pré-processamento é melhorar o contraste, reduzir ruído e realçar bordas antes da segmentação. Foram avaliados os seguintes métodos:

- **Original:** imagem sem modificações;
- **CLAHE:** aplicando o CLAHE, uma equalização adaptativa de histograma que melhora o contraste local;
- **Normalize:** normalização da intensidade;
- **Bilateral Filter:** redução de ruído utilizando filtro bilateral;
- **Sharpen:** utilização do sharpen para o realce de contornos;
- **CLAHE + Bilateral;**
- **CLAHE + Sharpen;**
- **Normalize + Sharpen.**

3.3 Segmentação

Para cada versão pré-processada da imagem, foram aplicados três grupos de segmentadores, baseados nos espaços de cor HSV, Lab e tons de cinza.

3.3.1 Segmentação em HSV

No HSV, o H representa a cor (Matiz), o S de saturação e o V representa o brilho. Ele é útil para segmentar a cor laranja (normalmente a cor das bolas de basquete) pois mesmo que mude o brilho e a saturação, o H (Matiz) permanece mais estável na maior parte das imagens. Utilizando o HSV foram avaliados os seguintes métodos:

- **HSV + Filtro:** segmentação por faixa de cor;
- **HSV + Hough:** segmentação em HSV seguida uso da técnica Hough, usada para detectar círculos;
- **HSV + Otsu:** limiarização automática após segmentar a cor laranja;
- **HSV + Multi-Otsu:** semelhante ao anterior mas com múltiplos limiares.

3.3.2 Segmentação em LAB

Nesse caso, o L se refere a luminosidade, e o A e o B são os tons de cores. O A representa do verde até o vermelho e o B do azul até o amarelo, logo para chegar na cor laranja necessitamos buscar locais com valores altos em ambos.

O Lab é testado além do HSV porque ele é mais robusto à iluminação, separa cor e brilho de forma mais eficiente e representa cores de forma perceptualmente uniforme, o que pode melhorar significativamente a segmentação da bola em cenários difíceis. Os métodos avaliados foram:

- **Lab + Filtro:** segmentação utilizando o Lab;
- **Lab + Hough:** segmentação seguida de detecção de círculos;
- **Lab + Otsu:** limiarização automática após o uso do Lab;
- **Lab + Multi-Otsu:** determinação de múltiplos limiares.

3.3.3 Segmentação em Tons de Cinza

Por último foi testado somente com imagens em tons de cinza. Ele provavelmente não terá um desempenho bom na maioria das imagens, mas pode ser interessante em alguns casos. Foram testados:

- **Gray + Otsu;**
- **Gray + Multi-Otsu;**
- **Gray + Hough;**
- **Gray + Otsu + Hough.**

3.4 Pós-processamento

Independentemente do método utilizado, cada máscara gerada foi refinada por meio da função `posproc_mask`. Passamos por 4 etapas:

- **Binarizar:** garantimos que só tenha 0 ou 255 nas imagens;
- **Fechamento:** usado o fechamento para retirar possíveis buracos;
- **Retirar contorno mais elíptico:** como só temos uma bola em cada imagem, porém podem ter vários 'objetos', buscamos o mais elíptico, já que na maioria dos casos a bola não está totalmente redonda. Fazemos uma lista, caso o mais elíptico seja muito pequena, não pode ser a bola, então pegamos o próximo;
- **Bounding Box:** como a máscara real está representada com uma bounding box em volta da bola, fazemos o mesmo para chegar mais próximo possível.

3.5 Avaliação da Segmentação

A qualidade da segmentação é avaliada utilizando o coeficiente de Dice, definido por:

$$\text{Dice} = \frac{2|X \cap Y|}{|X| + |Y|}$$

onde X representa a máscara predita e Y a máscara real. O valor varia entre 0 e 1, sendo 1 uma segmentação perfeita.

3.6 Seleção do Melhor Método por Imagem

Para cada imagem:

1. todas as combinações de pré-processamento e segmentação foram avaliadas;
2. o melhor valor de Dice foi selecionado;
3. uma *bounding box* foi desenhada sobre a imagem original utilizando a melhor máscara;
4. a imagem resultante foi salva na pasta `results/`.

3.7 Ranking Final dos Métodos

Ao final do processamento de toda a base, foi calculada a média do coeficiente de Dice de cada método. Os métodos foram então ordenados em ordem decrescente de desempenho, formando um ranking que permite identificar as melhores estratégias de segmentação considerando o conjunto completo de imagens.

4 Resultados e Discussões

Nesta seção são apresentados os resultados obtidos pelos diferentes métodos de pré-processamento e segmentação aplicados às 30 imagens avaliadas. Cada combinação de técnicas gerou uma máscara binária, cuja qualidade foi medida pelo coeficiente de Dice em relação à máscara real.

Os códigos e resultados completos estão disponíveis no Google Colab Seiji (2025a) e no repositório GitHub Seiji (2025b).

A Tabela 1 apresenta, para cada imagem, o melhor resultado obtido.

Tabela 1: Melhor resultado de Dice por imagem

Imagem	Dice	Pré-processamento	Método de Segmentação
100.jpg	0.7995	Original	Lab + Multi-Otsu
106.jpg	0.7093	Sharpen	Lab + Multi-Otsu
107.jpg	0.7944	Original	HSV + Hough
110.jpg	0.8429	Original	HSV + Filtro
114.jpg	0.8536	Sharpen	HSV + Filtro
115.jpg	0.8791	Original	Lab + Multi-Otsu
12.jpg	0.8273	Bilateral	HSV + Filtro
122.jpg	0.9162	CLAHE + Bilateral	HSV + Filtro
135.jpg	0.7010	Bilateral	HSV + Filtro
143.jpg	0.7759	CLAHE + Bilateral	HSV + Filtro
146.jpg	0.9251	Original	HSV + Filtro
19.jpg	0.9434	Sharpen	HSV + Filtro
2.jpg	0.9945	CLAHE	Lab + Filtro
23.jpg	0.9105	Original	HSV + Hough
26.jpg	0.6935	Sharpen	HSV + Filtro
32.jpg	0.8905	Sharpen	Lab + Multi-Otsu
35.jpg	0.8732	Sharpen	Lab + Filtro
4.jpg	0.6873	Bilateral	HSV + Filtro
44.jpg	0.7888	CLAHE	HSV + Filtro
46.jpg	0.5356	Bilateral	HSV + Filtro
5.jpg	0.8492	CLAHE + Sharpen	Lab + Filtro
50.jpg	0.7533	Sharpen	Lab + Multi-Otsu
6.jpg	0.7413	Original	HSV + Hough
70.jpg	0.7312	Sharpen	HSV + Filtro
74.jpg	0.7945	CLAHE	HSV + Filtro
75.jpg	0.5808	CLAHE	HSV + Filtro
81.jpg	0.8669	CLAHE + Bilateral	HSV + Filtro
83.jpg	0.9162	CLAHE + Bilateral	Gray + Otsu + Hough
84.jpg	0.7970	Original	HSV + Filtro
94.jpg	0.7542	CLAHE + Bilateral	Lab + Multi-Otsu

4.1 Desempenho Geral dos Métodos

De maneira geral, os resultados mostram que a segmentação baseada no espaço de cor HSV apresentou desempenho superior em relação aos métodos baseados em Lab e em escala de cinza. Entre as combinações testadas, o conjunto **CLAHE com HSV + Filtro** apresentou

a maior média de Dice, atingindo **0.4771**, destacando-se como o método mais consistente entre as imagens avaliadas. Avaliando as imagens, das 30 somente 10 acabou identificando um local diferente. Em todos os outros acabaram identificando alguma parte da bola, por mais que não tenha resultado igual a máscara real, o que justifica o Dice não muito alto.

A maior parte dos melhores resultados individuais (incluindo Dice superiores a 0.90) também ocorreu em métodos baseados em HSV. Isso sugere que o espaço HSV, ao separar intensidade de cor, foi mais eficaz para isolar os tons alaranjados característicos da bola de basquete.

Por outro lado, em alguns casos onde o HSV não foi o melhor, se destacou como uma alternativa o Lab utilizando o Sharpen como pré-processamento e combinando com o Multi-Otsu na segmentação. Esse modelo foi líder em algumas imagens, representando um bom modelo em alguns casos.

Por último, as imagens em tom de cinza apresentou uma clara desvantagem em relação aos outros dois métodos, de modo que na grande maioria das imagens apresentou uma deficiência em detectar a bola de basquete, não sendo ideal para esse projeto.

4.2 Análise dos 10 melhores modelos no geral

Dentre todos os modelos testados, os 10 com melhores médias de Dice estão representadas na tabela 2:

Tabela 2: Top 10 melhores métodos segundo a média do coeficiente de Dice

Método	Média Dice
CLAHE HSV + Filtro	0.4771
Bilateral HSV + Filtro	0.4339
CLAHE + Bilateral HSV + Filtro	0.3844
Original HSV + Filtro	0.3627
Normalize HSV + Filtro	0.3627
Sharpen HSV + Filtro	0.3579
Normalize + Sharpen HSV + Filtro	0.3579
CLAHE Lab + Multi-Otsu	0.3002
Original HSV + Hough	0.2893
Normalize HSV + Hough	0.2867

A análise dos dez melhores métodos revela uma tendência clara: as maiores médias do coeficiente de Dice são obtidas principalmente utilizando o espaço de cor HSV, tendo 9 modelos no top 10. O único método com um espaço de cor diferente seria o Lab utilizado com o Multi-Otsu, o que pode representar uma boa alternativa em exemplos onde o HSV não obteve um resultado muito bom.

O desempenho superior do HSV pode ser atribuído à sua separação entre componentes de cor (H) e intensidade (V), tornando-o menos sensível a variações de iluminação. Isso favorece a detecção da bola de basquete, que apresenta coloração marcante.

Um ponto importante a ser destacado seria que somente o HSV filtrando com a cor laranja foi o melhor, ao combinar com Hough, Otsu e Multi-Otsu o desempenho não seguiu muito alto. O pré-processamento com CLAHE teve um desempenho ótimo, enquanto o Normalize e Sharpen não apresentaram uma grande mudança de Dice se comparar entre eles.

4.3 Análise dos 10 piores modelos no geral

Agora na tabela 3 estão representadas os piores modelos, não acertando praticamente nada.

Tabela 3: Top 10 piores métodos segundo a média do coeficiente de Dice

Método	Média Dice
CLAHE + Bilateral Gray + Multi-Otsu	0.0252
Bilateral Gray + Otsu	0.0227
CLAHE Gray + Multi-Otsu	0.0155
Original Gray + Otsu	0.0578
Normalize Gray + Otsu	0.0578
CLAHE HSV + Multi-Otsu	0.0631
Original Gray + Multi-Otsu	0.0674
Normalize Gray + Multi-Otsu	0.0674
CLAHE + Sharpen Gray + Otsu + Hough	0.0368
CLAHE + Sharpen Gray + Hough	0.0716

Os dez piores métodos apresentam um padrão claro: quase todos utilizam o espaço de cor em escala de cinza, que se mostrou inadequado para segmentar a bola de basquete. A conversão para Gray remove informações cromáticas essenciais, dificultando a separação da bola do fundo em ambientes com texturas semelhantes em intensidade.

Além disso, métodos que combinam suavização (como o Bilateral) com técnicas de limitização multiclasse, como Multi-Otsu, criam máscaras fragmentadas, prejudicando totalmente a detecção. O desempenho ruim também é observado em métodos que adicionam a Transformada de Hough após uma segmentação já deficiente, fazendo com que o algoritmo tenha dificuldade em detectar círculos válidos.

A presença de um método HSV entre os piores (*CLAHE / HSV + Multi-Otsu*) reflete que o problema não é apenas o espaço de cor, já que por mais que o HSV com CLAHE tenha tido um resultado muito bom, ao adicionar o Multi-Otsu ele prejudica o resultado.

De modo geral, a ausência de informação de cor foi o fator mais prejudicial, explicando a predominância de métodos em escala de cinza nesta categoria.

4.4 Síntese dos Resultados

Os experimentos permitem concluir que:

- O espaço **HSV** apresentou o melhor compromisso entre consistência e desempenho geral.
- O espaço **Lab** pode atingir resultados excelentes em casos específicos.
- A escala de cinza se mostrou ruim para este problema.
- Técnicas de pré-processamento como **CLAHE**, **Sharpen** e filtros bilaterais podem melhorar resultados, mas seus efeitos dependem fortemente da imagem específica.
- No pós-processamento, filtros simples se saíram melhor que métodos baseados em Hough e Otsu.

5 Conclusão

O presente trabalho analisou diferentes estratégias de pré-processamento, segmentação e pós-processamento para a detecção de bolas de basquete em imagens. A partir da avaliação de combinações de técnicas aplicadas a um conjunto de 30 imagens, foi possível identificar quais abordagens apresentam melhor Dice.

Os resultados demonstraram de forma clara que o espaço de cor HSV foi o mais eficiente para este problema, alcançando as maiores médias de Dice e sendo responsável pela maioria dos melhores resultados individuais. A capacidade do HSV de separar a informação de cor da intensidade facilitou a identificação dos tons alaranjados característicos da bola, mesmo em condições adversas. Já o espaço Lab, embora não tenha sido o mais consistente, apresentou bom desempenho em alguns casos específicos, mostrando-se uma alternativa válida quando o HSV não é suficiente. Em contrapartida, os métodos baseados apenas em escala de cinza apresentaram desempenho bastante inferior, reforçando a importância da informação de cor para a segmentação da bola de basquete.

De modo geral, o pipeline desenvolvido demonstrou ser capaz de segmentar a bola em praticamente todas as imagens, ainda que com variação de desempenho entre os métodos. O projeto evidenciou a importância de testar múltiplas abordagens, uma vez que nenhum método único é totalmente dominante em todos os cenários.

Referências Bibliográficas

SEIJI, D. Notebook do projeto: Segmentação de bola de basquete. https://colab.research.google.com/drive/17iozq1PGgh0uLXBqywqEB0dlcGQ0_svp?usp=sharing, acessado em: 11-02-2025, 2025a.

SEIJI, D. Projeto final – processamento de imagens: Basketball segmentation. <https://github.com/DaviSeiji/ProjetoFinal---PI---BasketballSegmentation>, acessado em: 11-02-2025, 2025b.